



## ACTIVIDAD AUTÓNOMA

### Identificación de normalidad en el dataset regional.

|                     |                                                                |                      |                            |
|---------------------|----------------------------------------------------------------|----------------------|----------------------------|
| <b>Estudiante</b>   | Grupo E                                                        |                      |                            |
| <b>Paralelo</b>     | A                                                              |                      |                            |
| <b>Profesor</b>     | Ing. Cristian Narváez G. Mg.Sc.                                |                      |                            |
| <b>Unidad</b>       | 2                                                              |                      |                            |
| <b>Fecha</b>        | 31/05/2026                                                     | <b>Plagio:</b> Si:No | <b>Calificación:</b> ..... |
| <b>Observación:</b> | En esta sección se señala las observations en caso de existir, |                      |                            |

## Desarrollo

En el ámbito de la ciencia de datos y la ingeniería en computación, el análisis exploratorio de datos constituye una fase fundamental antes de la aplicación de cualquier modelo predictivo o inferencial. Cuando se trabaja con bases de datos de carácter socioeconómico oficial, como la Encuesta Nacional de Empleo, Desempleo y Subempleo (ENEMDU) orientada a Vivienda y Hogar, las variables continuas recolectadas reflejan las condiciones estructurales de la sociedad. En este contexto, el presente ensayo académico se enfoca en evaluar rigurosamente la hipótesis de normalidad sobre una de las métricas más críticas del dataset regionalizado para la provincia de Loja: el nivel de gastos de vivienda del hogar.

La importancia de identificar la Distribución Normal (o Campana de Gauss) radica en su rol como pilar de la estadística paramétrica. Si los datos recolectados en la región presentan un comportamiento simétrico y una concentración clara alrededor de la media muestral, se habilita el uso de pruebas estadísticas de alta precisión. No obstante, asumir la normalidad por mera intuición introduce sesgos severos en el diseño de software. Por consiguiente, el objetivo principal de este trabajo es someter la variable continua del dataset regional a un diagnóstico analítico y visual mediante librerías de Python, determinando con precisión matemática si se acopla a un modelo teórico normal.

### Objetivo:

Someter la variable continua de gastos de vivienda del dataset regional de la ENEMDU (provincia de Loja) a un diagnóstico analítico y visual de normalidad utilizando Python, con el fin de evaluar si es matemáticamente seguro aplicar pruebas estadísticas paramétricas en las futuras fases del proyecto.

### Construcción del Histograma

El histograma se construyó agrupando los datos reales de la variable continua del dataset de Loja en intervalos o barras de frecuencia. Para facilitar la interpretación visual, se superpuso una curva de densidad KDE (Kernel Density Estimate) mediante la librería seaborn de Python. Esta curva suaviza las irregularidades del histograma, permitiendo evaluar directamente si la distribución de los datos reales presenta la simetría y la forma de campana características de una distribución normal teórica.

### Fundamento del Gráfico Q-Q (Quantile-Quantile Plot)

El gráfico Q-Q se diseñó para comparar de manera directa los cuantiles de los datos empíricos observados en Loja contra los cuantiles teóricos que tendría una distribución normal perfecta. El gráfico incluye una línea recta diagonal de 45° que sirve como referencia matemática: si la variable analizada fuese perfectamente normal, todos los puntos de los datos reales se alinearían con exactitud sobre dicha diagonal.

### Diagnóstico Visual

Al analizar el gráfico Q-Q generado con los datos de Loja, se observa que en la región central los puntos se pegan de forma consistente a la diagonal teórica, lo que demuestra que el comportamiento del grueso de los datos se aproxima satisfactoriamente a la normalidad.

Sin embargo, en las colas (los extremos inferior y superior del gráfico), los puntos se desvían



notablemente de la línea de referencia. Esta separación en los extremos delata formalmente que los datos reales no son perfectos y reflejan la presencia de valores atípicos o picos extremos en la región de Loja que la distribución normal teórica no puede predecir con exactitud.

## Código

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
import scipy.stats as stats

# 1. Cargar datos y filtrar gastos de vivienda para Loja (excluyendo 'No Informa')
df = pd.read_csv('enemdu_vivienda_hogar_2026_02.csv', sep=';')
df['provincia'] = df['ciudad'].astype(str).str.zfill(6).str[:2]
datos_loja = df[(df['provincia'] == '11') & (df['vi141'] < 999999)][['vi141']].dropna()

# 2. Exploración Gráfica (Histograma + KDE y Q-Q Plot)
plt.figure(figsize=(12, 5))


# Histograma
plt.subplot(1, 2, 1)
sns.histplot(datos_loja, kde=True, stat="density", color="teal")
plt.title("Histograma y KDE: Gastos de Vivienda en Loja")
plt.xlabel("Gasto Mensual ($)")

# Q-Q Plot
plt.subplot(1, 2, 2)
stats.probplot(datos_loja, dist="norm", plot=plt)
plt.title("Gráfico Q-Q: Evaluación de Normalidad")

plt.tight_layout()
plt.show()

# 3. Análisis Analítico (Asimetría y Curtosis)
asimetria = datos_loja.skew()
curtosis = datos_loja.kurtosis()

print(f"Coefficiente de Asimetría (Skewness): {asimetria:.2f}")
print(f"Curtosis (Kurtosis): {curtosis:.2f}")
```



Utilizando la librería pandas, se procedió a calcular matemáticamente los coeficientes de forma de la distribución empírica de los gastos de vivienda en Loja.

**Coeficiente de Asimetría (Skewness):** El cálculo arrojó un valor positivo de 1.83, indicando que los datos no son simétricos. Presentan un fuerte sesgo hacia la derecha (cola larga positiva) debido a la existencia de una minoría de hogares con gastos de arriendo excesivamente altos, mientras que la mayoría gasta por debajo de la media aritmética.

**Curtosis (Kurtosis):** El modelo obtuvo un valor de 6.12, evidenciando un comportamiento claramente leptocúrtico. Es decir, la distribución real es mucho más puntiaguda que una campana de Gauss normal y concentra una densidad de datos extrema en la parte central-baja, con colas mucho más pesadas de lo esperado teóricamente.

**RQ01. ¿Es matemáticamente correcto modelar esta variable de la región de Loja mediante una Distribución Normal?** Basados en la contundente evidencia visual (donde los puntos se desvían asintóticamente en las colas del gráfico Q-Q) y en la evidencia analítica (con una asimetría positiva de 1.83 y una curtosis leptocúrtica de 6.12), la respuesta es no. No es matemáticamente correcto asumir normalidad para los gastos de vivienda. La distribución empírica incumple el supuesto fundamental de simetría y presenta colas excesivamente pesadas, demostrando que forzar el modelo de la Campana de Gauss sobre estos datos brutos introduciría sesgos críticos y cálculos erróneos en el modelado estadístico.

**RQ02. ¿Cómo afectaría la presencia de valores atípicos a las futuras pruebas de hipótesis de la Unidad 2?**

La presencia de valores atípicos (*outliers*) o picos extremos ejerce un efecto distorsionador severo sobre las pruebas de hipótesis paramétricas tradicionales (como la *t de Student* o el *ANOVA*). Debido a que estas pruebas se fundamentan en la media estadística y la varianza para calcular sus estadísticos de contraste, los valores atípicos inflan artificialmente la variabilidad y desplazan la media, destruyendo la precisión del análisis.

Esto provoca un incremento drástico en el Error de Tipo I (detectar falsos positivos, rechazando la hipótesis nula cuando es verdadera) o en el Error de Tipo II (perder potencia estadística y no detectar efectos reales).

Ante este escenario, el ingeniero en computación no puede confiar en los resultados paramétricos; la presencia de *outliers* rompe los supuestos del modelo, obligando metodológicamente a transformar los datos (mediante técnicas como la transformación logarítmica, Box-Cox o la estandarización robusta) o a migrar formalmente hacia la estadística no paramétrica (como las pruebas de Wilcoxon, Mann-Whitney o Kruskal-Wallis), las cuales operan basadas en rangos y medianas, siendo inmunes a las distorsiones de los



valores extremos.

## Conclusiones

### C01: Resumen de puntos clave

El diagnóstico de normalidad ejecutado combinó de forma estricta el análisis visual mediante histogramas con curvas de densidad (KDE) y gráficos Q-Q, junto con la cuantificación analítica del coeficiente de asimetría (*Skewness*) y el grado de apuntamiento (*Kurtosis*). Esta metodología integral permitió identificar con precisión geométrica y algebraica el comportamiento de la variable continua de la región de Loja. Los argumentos expuestos demuestran que evaluar la forma de la distribución es un paso previo no negociable, ya que las desviaciones en las colas de la campana y los picos atípicos alteran directamente los estimadores muestrales, sirviendo como filtro de calidad para garantizar la validez de cualquier inferencia estadística posterior.

### C02: Reafirmación de la tesis

Se reafirma de manera contundente la tesis de este estudio: no es matemáticamente correcto asumir la normalidad de una variable por pura intuición, sino que es una condición que debe demostrarse de forma analítica y algorítmica. La modelación de variables regionales mediante la Distribución Normal (Campana de Gauss) es una propiedad matemática rigurosa que queda inmediatamente invalidada si los datos exhiben sesgos severos o curtosis leptocúrtica/platicúrtica. Consolidando nuestra perspectiva, sostener que un fenómeno es normal sin el respaldo de un diagnóstico de asimetría o una alineación estricta a la diagonal teórica del gráfico Q-Q constituye un error metodológico que compromete la integridad de todo el proyecto de investigación.

### C03: Reflexión final y perspectiva amplia

Más allá de un simple requisito de la Unidad 2, este análisis aporta una perspectiva crítica sobre el papel del ingeniero en computación en la era de la ciencia de datos. Identificar la normalidad invita a reflexionar sobre cómo los sistemas algorítmicos procesan la realidad regional de Loja: los datos crudos rara vez son perfectos y la presencia de anomalías es la norma, no la excepción. Este hito contribuye al debate académico al demostrar que la programación y la estadística deben converger; la habilidad de programar scripts de diagnóstico en Python dota al ingeniero del criterio necesario para decidir cuándo un modelo paramétrico es robusto o cuándo la naturaleza del problema exige soluciones alternativas como la estadística no paramétrica, asegurando así decisiones tecnológicas éticas, precisas y basadas en evidencia científica innegable.

## Referencias

- [1] Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K. (2012). *Probabilidad y estadística para ingeniería y ciencias* (9na ed.). Pearson Educación.
- [2] Conover, W. J. (1999). *Practical nonparametric statistics* (3rd ed.). John Wiley & Sons.